

UNIVERSIDAD CATÓLICA BOLIVIANA “SAN PABLO”

Sede Santa Cruz

Redes Neuronales y Aprendizaje Profundo

PROYECTO FINAL

Asistente Turístico Inteligente para Santa Cruz

Reconocimiento de Lugares, Verificación de Identidad y Traducción Multilingüe

1. Contexto del problema

Santa Cruz de la Sierra recibe cada año un número creciente de visitantes nacionales y extranjeros. Una startup local, **“RutaCruceña”**, está desarrollando una aplicación de turismo que permite a los viajeros apuntar la cámara hacia un lugar emblemático y obtener al instante el nombre del sitio, una breve descripción y datos útiles, sin depender de metadatos GPS (que muchas fotos no tienen, ya sea por privacidad o porque la cámara no los registra).

La aplicación es un servicio de pago dirigido a **guías turísticos acreditados**. Para evitar el abuso de las llamadas al modelo (que tienen un costo de cómputo), antes de atender cualquier solicitud el sistema debe **verificar que quien hace la petición es realmente el guía que dice ser**. Esto se resuelve con un módulo de re-identificación de personas: el usuario declara una identidad y presenta una imagen; el sistema la compara contra la galería de guías registrados y solo concede acceso si la coincidencia es válida.

Una vez verificada la identidad, el guía envía una foto de un lugar. El modelo de visión predice de qué sitio se trata (por ejemplo, la **Plaza 24 de Septiembre**, la **Catedral**, el **Cristo Redentor**, **Samaipata / El Fuerte**, la **Laguna Volcán**, el **Biocentro Güembé**, etc.). Como los turistas hablan distintos idiomas, la respuesta debe entregarse también traducida a **inglés, francés e italiano** mediante un modelo de lenguaje (LLM).

Todo el ciclo de experimentación (entrenamiento, métricas, comparación de arquitecturas) debe quedar registrado en **Weights & Biases (WandB)**, y el producto final debe exponerse mediante una **API construida con FastAPI** más una **interfaz de usuario** (Gradio o Streamlit, a elección) que consuma esa API.

Ustedes son el equipo de Machine Learning de RutaCruceña. Reciben este enunciado de negocio y deben diseñar la solución técnica completa con autonomía: elegir arquitecturas, armar el dataset local, definir umbrales razonables, integrar los módulos y entregar un sistema funcional defendible. El enunciado describe QUÉ debe lograr el sistema y CÓMO se evaluará; el CÓMO técnico es decisión de ustedes y parte central de la nota.

2. Objetivos

2.1 Objetivo general

Diseñar, entrenar, evaluar, registrar y desplegar un sistema de visión por computadora que reconozca lugares turísticos locales a partir de una imagen, condicionado a una verificación previa de identidad por re-identificación, y que entregue resultados traducidos a varios idiomas mediante un LLM, exponiendo todo a través de una API y una interfaz interactiva.

3. Descripción del sistema (módulos requeridos)

El sistema se compone de cinco módulos. El grupo decide los detalles de implementación de cada uno, respetando los requisitos mínimos indicados.

3.1 Módulo A — Verificación de identidad por Re-ID (control de acceso)

Actúa como “puerta de entrada”: ninguna solicitud de reconocimiento de lugar se procesa si la identidad no fue verificada.

- Mantener una galería de identidades registradas (cada identidad con una o varias imágenes de referencia). Pueden usar un dataset de rostros/personas público, recortes de personas, o incluso adaptar el enfoque del proyecto de re-ID sobre un dataset controlado. Lo importante es el mecanismo, no el dominio exacto.
- Entrenar (o reutilizar) una red que produzca un vector de embedding por imagen. El ranking de la galería se hace por distancia (por ejemplo, euclidiana o coseno) entre el embedding de la consulta (query/probe) y los de la galería.
- Decisión de acceso: el usuario declara una identidad; el sistema concede acceso solo si la identidad declarada coincide con el top-1 (o top-k con verificación) de la galería bajo un umbral de distancia justificado.
- Reportar métricas de recuperación: top-1, top-k y mAP (usar la variante correcta de mAP para re-identificación).
- Visualizar el espacio de embeddings (proyección 2-D, p. ej. con PCA o t-SNE) mostrando la separación entre identidades.

3.2 Módulo B — Clasificación de landmarks locales

Es el núcleo del sistema. Deben implementar y comparar dos enfoques sobre el mismo dataset de lugares.

Enfoque B1 — CNN desde cero (from scratch)

- Arquitectura propia con al menos 3 capas convolucionales, pooling, normalización (BatchNorm), dropout y capas fully-connected. Justificar el diseño.
- Definir función de pérdida y optimizador; entrenar por al menos 30 épocas registrando train/val loss y accuracy por época.
- Guardar el mejor modelo (menor val loss) y exportarlo con TorchScript (torch.jit).

Enfoque B2 — Transfer Learning

- Seleccionar al menos un modelo preentrenado de torchvision (ResNet18/50, EfficientNet, VGG16, etc.) y justificar la elección por escrito.
- Congelar el feature extractor, reemplazar la capa clasificadora y entrenar; luego, opcionalmente, hacer fine-tuning de las últimas capas.
- Comparar contra B1 en una tabla y/o gráfico (accuracy, número de parámetros, tiempo de entrenamiento, tamaño del modelo).

Umbralés mínimos de rendimiento (sobre el test set local)

- **CNN desde cero:** Test Accuracy $\geq 45\%$.
- **Transfer Learning:** Test Accuracy $\geq 75\%$ y debe superar al modelo B1.

***Nota:** el dataset local es más pequeño y “ruidoso” que un benchmark; los umbrales reflejan esa dificultad. Documenten cómo lo abordaron (augmentation, balanceo de clases, etc.).*

3.3 Módulo C — Traducción multilingüe con LLM

- La salida del reconocimiento (nombre del lugar + descripción breve generada o curada por el grupo) debe traducirse a inglés, francés e italiano usando un LLM (vía API de un proveedor, un modelo local/open-source, o el LLM que el grupo justifique).
- El LLM también debe usarse para normalizar/traducir las solicitudes de entrada cuando lleguen en un idioma distinto al esperado (p. ej. un guía que escribe la consulta en otro idioma).
- Manejar el caso de error del LLM (timeout, sin conexión, respuesta vacía) con un fallback claro. El sistema no debe “caerse” si el LLM falla.

3.4 Módulo D — Experiment tracking con WandB

- Todos los entrenamientos (B1, B2 y el de re-ID) deben registrarse en WandB: curvas de loss/accuracy, hiperparámetros (config), métricas finales y, al menos, el mejor checkpoint como artifact.
- Incluir en el informe capturas o enlaces (compartibles) a los dashboards/runs de WandB que permitan comparar los experimentos.
- Se valora el uso de comparación de runs (parallel coordinates, tablas de sweeps o, como bonus, un hyperparameter sweep).

3.5 Módulo E — API (FastAPI) e interfaz (Gradio/Streamlit)

- Construir una API con FastAPI que cargue los modelos exportados (TorchScript) y exponga, como mínimo: (a) un endpoint de verificación de identidad, (b) un endpoint de predicción de lugar que solo responda si la identidad fue verificada, y (c) la traducción multilingüe de la respuesta.
- La API NO debe re-entrenar: solo consume los modelos ya entrenados y exportados.
- Construir una interfaz (Gradio o Streamlit, a elección del grupo) que consuma la API: subir imagen de verificación, declarar identidad, subir imagen del lugar y mostrar la predicción top-k con probabilidades y las traducciones.
- Documentar cómo levantar la API y la interfaz (comandos, puertos, variables de entorno para claves del LLM).

Flujo extremo a extremo (end-to-end) que se debe demostrar

- 1) El usuario declara una identidad y sube una imagen de verificación. → Módulo A decide si concede acceso (Re-ID + umbral).
- 2) Si hay acceso, el usuario sube la foto de un lugar. → Módulo B predice el landmark (top-k + probabilidades).
- 3) La respuesta (nombre + descripción) se traduce a EN/FR/IT. → Módulo C (LLM).
- 4) Todo el entrenamiento previo quedó registrado en WandB (**Módulo D**) y todo se sirve por la API + interfaz (**Módulo E**).

4. Dataset de lugares locales

No se entrega un dataset cerrado: parte del trabajo es construirlo. El sistema es para una aplicación turística real de la región, por lo que las clases deben ser lugares locales.

- Mínimo 8 clases (lugares). Sugeridos: Plaza 24 de Septiembre, Catedral Metropolitana, Cristo Redentor, Parque Urbano, Jardín Botánico, Biocentro Güembé, El Fuerte de Samaipata, Laguna Volcán, Lomas de Arena, Ventura Mall, entre otros.
- Mínimo 60–100 imágenes por clase, capturadas desde distintos ángulos, distancias, horas e iluminación (pueden combinar fotos propias e imágenes de internet, citando la fuente).
- Particiones train / validation / test sin solapamiento. La validación debe salir del train; el test no debe usarse para seleccionar el modelo.
- Preprocesamiento: resize a 256px, recorte central a 224px y normalización con media/desviación de ImageNet (necesario para Transfer Learning).
- Data augmentation en entrenamiento (flips, rotaciones, jitter de color, etc.). Analizar la distribución de clases y reportar si hay desbalance.

Importante sobre el dataset

NO suban el dataset de imágenes al repositorio. Provean un script o instrucciones para reconstruirlo, o un enlace de descarga (AWS S3). Documenten el origen de cada conjunto de imágenes y respeten derechos de autor/licencias.

5. Fases del proyecto

Fase	Actividades principales
Fase 1 — Datos	Recolección, exploración, análisis de distribución de clases, transformaciones, augmentation y DataLoaders (train/val/test).
Fase 2 — Re-ID	Implementar el módulo de verificación de identidad (embeddings, ranking por distancia, umbral, métricas top-k y mAP, visualización del espacio).
Fase 3 — Clasificación	Entrenar la CNN desde cero (B1) y el modelo de Transfer Learning (B2); comparar resultados; exportar con TorchScript.
Fase 4 — LLM	Integrar el LLM para traducir la salida a EN/FR/IT y normalizar solicitudes de entrada; manejar errores y fallback.
Fase 5 — WandB	Registrar todos los experimentos, comparar runs y exportar artefactos/checkpoints.
Fase 6 — Despliegue	Construir la API con FastAPI y la interfaz Gradio/Streamlit; integrar el flujo end-to-end y documentar el arranque.
Fase 7 — Informe y defensa	Redactar el informe (formato pregunta–respuesta donde aplique), grabar el video y preparar la defensa oral.

7. Entregables

- Repositorio GitHub público con todo el código fuente organizado.
- Notebooks Jupyter ejecutados (.ipynb) con todas las celdas corridas y salidas visibles (curvas, tablas, visualizaciones).
- Código de la API (FastAPI) y de la interfaz (Gradio/Streamlit) listos para ejecutarse.
- Modelos exportados con TorchScript (.pt) o instrucciones de descarga (NO subir el dataset).
- Informe (report.pdf): 10 páginas, formato pregunta–respuesta donde corresponda, con decisiones de diseño, resultados, comparaciones, métricas finales y enlaces a WandB.
- README.md con instrucciones de instalación, ejecución de cada módulo, arranque de la API/interfaz y descripción del proyecto.
- Defensa oral de 3 a 5 minutos explicando resultados y decisiones.
- Enlace al proyecto/runs de WandB (compatible).

7.1 Estructura sugerida del repositorio

```
asistente-turistico/
├── README.md
├── requirements.txt
├── notebooks/
│   ├── 01_datos_eda.ipynb
│   ├── 02_reid.ipynb
│   ├── 03_cnn_scratch.ipynb
│   └── 04_transfer_learning.ipynb
├── src/
│   ├── data.py
│   ├── model.py          # CNN, backbone TL y red de embeddings (Re-ID)
│   ├── train.py          # logging a WandB
│   ├── reid.py           # galería, ranking, umbral, mAP
│   ├── translate.py      # integración con el LLM (EN/FR/IT) + fallback
│   └── predictor.py      # carga TorchScript e inferencia top-k
├── api/
│   └── main.py           # FastAPI: /verify, /predict, /translate
├── ui/
│   └── app.py            # Gradio o Streamlit que consume la API
├── models/              # .pt exportados (o enlace de descarga)
├── ETL/                 # ETL para la preparación de los datos
└── report.pdf
```

Se sugiere usar un S3 para el almacenamiento de los datos y crear una ETL para la preparación de sus datos.

8. Defensa oral

Posibles ejes de preguntas (no exhaustivos):

- ¿Por qué eligieron esa arquitectura de CNN y ese modelo preentrenado? ¿Cuántos parámetros tiene cada uno y por qué hay diferencia?
- ¿Cuál es la diferencia entre clasificación e image retrieval/re-ID? ¿Por qué pueden entrenar la red de retrieval con una pérdida de clasificación?
- ¿Qué representa el espacio de embeddings? ¿Qué significa la distancia entre vectores y cómo eligieron el umbral de acceso?
- ¿Qué es overfitting? ¿Cómo lo detectaron y mitigaron? ¿Qué relación hay entre batch size y learning rate?
- ¿Cómo definieron y midieron el mAP en re-ID? ¿Por qué es diferente del mAP de detección de objetos?
- ¿Cómo manejan un fallo del LLM o una solicitud en un idioma inesperado?
- Muestren en WandB la comparación de experimentos y expliquen qué los llevó a su modelo final.
- Hagan una demostración en vivo del flujo end-to-end en la interfaz.

9. Rúbrica de evaluación (100 puntos)

Cada criterio se evalúa según el cumplimiento de los requerimientos. La defensa oral puede ajustar la nota individual cuando un integrante no demuestre comprensión del trabajo presentado.

Criterio	Puntos
FASE 1 — Datos y preprocesamiento	10 pts
Dataset local con ≥ 8 clases y volumen adecuado por clase; origen documentado y derechos respetados.	4
EDA: ejemplos etiquetados, distribución de clases y análisis de desbalance.	3
Transformaciones (resize/crop/normalización), augmentation y DataLoaders train/val/test sin solapamiento.	3
FASE 2 — Verificación de identidad (Re-ID)	15 pts
Red de embeddings y galería funcionando; ranking por distancia correctamente implementado.	5
Lógica de control de acceso con umbral justificado (acepta/rechaza identidad declarada).	4
Métricas de recuperación: top-1, top-k y mAP (variante correcta de re-ID).	3
Visualización del espacio de embeddings (PCA/t-SNE) con interpretación.	3
FASE 3 — Clasificación de landmarks	20 pts
CNN desde cero: arquitectura propia justificada (≥ 3 conv, pooling, BatchNorm, dropout, FC).	3
Entrenamiento CNN (≥ 30 épocas), curvas train/val de loss y accuracy, mejor modelo guardado.	2
Rendimiento CNN: Test Accuracy $\geq 45\%$.	4
Transfer Learning: modelo preentrenado elegido y justificado; congelar + nueva FC; fine-tuning opcional.	4
Rendimiento TL: Test Accuracy $\geq 75\%$ y supera a la CNN; comparación en tabla/gráfico.	5
Exportación de ambos modelos con TorchScript (torch.jit) y prueba de carga.	2
FASE 4 — Traducción multilingüe (LLM)	5 pts
Traducción correcta de la salida a inglés, francés e italiano mediante un LLM.	2
Normalización/traducción de solicitudes de entrada en idioma inesperado.	2
Manejo de errores del LLM (timeout/sin conexión) con fallback claro.	1
FASE 5 — Experiment tracking (WandB)	5 pts

Criterio	Puntos
Todos los entrenamientos registrados (curvas, config, métricas finales).	3
Comparación de runs y al menos un checkpoint guardado como artifact; enlaces en el informe.	2
FASE 6 — API e interfaz	5 pts
API FastAPI con endpoints de verificación, predicción (condicionada) y traducción; consume TorchScript sin re-entrenar.	3
Interfaz Gradio/Streamlit que consume la API y muestra el flujo end-to-end (top-k + traducciones).	2
FASE 7 — Defensa oral	40 pts
Informe claro y bien estructurado (formato pregunta–respuesta donde aplique) con decisiones y resultados.	5
Video de 3–5 min coherente con el informe.	3
Defensa oral (≤ 5 min): responde con claridad y demuestra comprensión integral del sistema.	7
TOTAL	100 pts

10. Política de integridad académica

Existen recursos en línea muy similares a este proyecto. Está permitido consultarlos como referencia y para construir entendimiento, pero no copiar y pegar código o material directamente. El trabajo debe ser independiente y todas las fuentes utilizadas deben citarse. La discusión entre pares está permitida siempre que no se compartan código ni materiales. Cualquier forma de plagio detectada implica 0 puntos en el proyecto.

Pueden usar el dataset de google para landmarks: <https://github.com/cvdfoundation/google-landmark>

Para el ReID consultar este documento: L. Zheng, H. Zhang, S. Sun, M. Chandraker, Y. Yang, and Q. Tian, “Person re-identification in the wild,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 1367–1376.

Opcional:

Módulo de predicción de calificación de la ruta o del lugar.